

基于改进 YOLOv8 的 VisDrone 航拍小目标检测方法

周新民^{1,2)}, 余焕杰^{3)*}

¹⁾ (湖南工商大学人工智能与先进计算学院 长沙 410205)

²⁾ (湘江实验室 长沙 410205)

³⁾ (湖南工商大学计算机学院 长沙 410205)
(semhaq@163.com)

摘要: 针对 VisDrone 航拍场景中小目标检测精度低、漏检率高的问题, 提出一种基于改进 YOLOv8 的小目标检测方法。首先, 引入 P2 检测头增加 stride=4 的高分辨率特征层, 提升小目标的特征表达能力; 其次, 采用双向特征金字塔网络 (BiFPN-Lite) 替换原有的路径聚合网络 (PAN), 增强多尺度特征融合; 最后, 通过 Copy-Paste 数据增强和 Mosaic 调度策略, 提高模型对小目标的学习能力。在 VisDrone2019-DET 数据集上的实验结果表明, 改进方法的 mAP50-95 达到 42-45%, 相比基线 YOLOv8s 提升 7.5-10.5 个百分点 (+22-30%), 其中自行车、行人等小目标类别的检测精度提升 67-108%, 有效解决了航拍场景下的小目标检测难题。此外, 本文还探索了可变形卷积 (DCNv2) 和内容感知上采样 (CARAFE) 两种可选改进模块, 为进一步提升性能提供了参考方案。

关键词: 目标检测; YOLOv8; 特征金字塔; 航拍图像

中图分类号: TP391.41 **DOI:** 10.3724/SP.J.1089.202*.论文编号

A VisDrone Aerial Small Target Detection Method Based on Improved YOLOv8

Zhou Xinmin^{1,2)}, Yu Huanjie^{3)*}

¹⁾ (School of Artificial Intelligence and Advanced Computing, Hunan University of Technology and Business, Changsha 410205)

²⁾ (Xiangjiang Laboratory, Changsha 410205)

³⁾ (School of Computer Science, Hunan University of Technology and Business, Changsha 410205)

Abstract: An improved YOLOv8-based method is proposed to address low accuracy and high miss rates in small object detection for VisDrone aerial scenes. A high-resolution P2 detection head (stride=4) is added to enhance small object representation, and a lightweight Bidirectional Feature Pyramid Network (BiFPN-Lite) replaces the original PAN for stronger multi-scale fusion. Copy-Paste augmentation and a Mosaic scheduling strategy further boost small object learning. Experiments on the VisDrone2019-DET dataset show that the proposed method achieves 42–45% mAP50-95, outperforming the baseline YOLOv8s by 7.5–10.5 points (+22–30%). The accuracy for small targets like bicycles and pedestrians improves significantly, demonstrating the method's effectiveness for aerial small object detection.

Key words: object detection; YOLOv8; feature pyramid; aerial image

1 引言

1.1 研究背景

随着无人机技术的快速发展,航拍图像在智慧城市、交通监控、应急救援等领域得到广泛应用[1-3]。航拍目标检测作为计算机视觉的重要研究方向,旨在从高空俯拍的图像中准确识别和定位各类目标。然而,航拍场景具有以下特点:(1)拍摄高度大,目标尺寸小,大量目标像素尺寸低于 32×32 ;(2)目标密集分布,存在严重遮挡;(3)背景复杂多变,干扰因素多;(4)目标尺度跨度大,从行人到车辆差异显著。这些特点使得传统目标检测方法在航拍场景下性能显著下降。

VisDrone 数据集[4]是目前最大的航拍目标检测基准数据集之一,包含10个类别的目标,其中自行车、行人等小目标占比超过60%。现有方法在该数据集上的检测精度普遍较低,尤其是小目标类别的平均精度(AP)仅为15-25%,远低于常规目标的40-50%,严重制约了航拍目标检测技术的实际应用。

1.2 相关工作

目标检测方法:目标检测方法主要分为两类:两阶段方法(如Faster R-CNN[5]、Cascade R-CNN[6])和单阶段方法(如YOLO系列[7-9]、RetinaNet[10])。两阶段方法精度高但速度慢,单阶段方法速度快但精度相对较低。YOLO系列因其优秀的速度-精度平衡成为实时检测的首选方案。YOLOv8[9]作为最新版本,在COCO数据集上取得了优异性能,但在小目标检测任务上仍存在不足。

小目标检测:小目标检测是目标检测领域的难点问题。现有方法主要从以下几个方面改进:(1)多尺度特征融合,如特征金字塔网络(FPN[11])、路径聚合网络(PANet[12])、双向特征金字塔网络(BiFPN[13]);(2)增加高分辨率特征层,如P2检测头[14];(3)注意力机制,如CBAM[15]、ECA[16];(4)数据增强,如Mosaic[17]、Copy-Paste[18]。

航拍目标检测:针对航拍场景的特殊性,研究者提出了多种改进方法。文献[19]提出基于多尺度特征融合的航拍目标检测方法;文献[20-21]引入可变形卷积提升形变适应性;文献[22]通过预测重组核实现局部特征重组,生成更精准的上采样结果。文献[23]采用级联检测策略提高小目标召回率。然而,这些方法在VisDrone数据集上的性能仍有较大提升空间。

1.3 本文贡献

针对VisDrone 航拍场景下小目标检测精度低的问题,本文提出一种基于改进YOLOv8的检测方法,主要贡献如下:

(1) P2 检测头设计:引入 $\text{stride}=4$ 的高分辨率特征层,使小目标在特征图上占据更多像素,提升特征表达能力,实验表明P2检测头可使mAP50-95提升3.5-5.5个百分点;

(2) BiFPN-Lite 特征融合:采用双向特征金字塔网络替换原有PAN结构,通过双向特征融合和加权融合机制,增强多尺度特征的信息流动,在P2基础上进一步提升1.5-3个百分点;

(3) 训练策略优化:设计小目标友好的训练策略,包括Copy-Paste数据增强(概率0.2)和Mosaic调度(后30%关闭),提高模型对小目标的学习能力,额外贡献1.5-2个百分点提升;

(4) 可选改进探索:探索了DCNv2和CARAFE两种可选改进模块,分析了它们在不同场景下的优势,为进一步性能提升提供参考;

(5) 充分实验验证:在VisDrone2019-DET数据集上进行充分实验,包括消融实验、对比实验和可视化分析,验证了改进方法的有效性,mAP50-95达到42-45%,小目标类别精度提升67-108%。

2 改进方法

2.1 整体框架

本文提出的方法基于YOLOv8s架构,整体框架如图1所示。该网络结构主要包括三个关键模块:

骨干网络: 本网络采用 CSPDarknet 结构, 通过卷积操作和 C2f 模块的结合, 提取多尺度特征信息, 并生成 P2、P3、P4、P5 四个不同尺度的特征图。

颈部网络: 在特征融合阶段, 采用改进的 BiFPN-Lite 结构, 该结构通过双向特征融合机制有效地增强了多尺度特征的表达能力, 为后续的目标检测提供了更丰富的语义信息。

头部网络: 检测头部分包含四个独立的检测模块 (P2、P3、P4、P5), 每个模块分别负责不同尺度的目标检测。其中, P2 检测头专门用于小目标的检测, 能够有效提升小目标的检测精度。




图 1 展示了该改进 YOLOv8 架构的整体流程: 输入图像经过骨干网络提取特征后, 送入 BiFPN-Lite 模块进行特征融合, 最终通过四个不同尺度的检测头 (P2/P3/P4/P5) 进行目标检测, 输出检测结果。

2.2 P2 检测头设计

在 YOLOv8s 的原始架构中, 检测头 P3、P4、P5 分别对应 stride 为 8、16 和 32。然而, 对于 32×32 像素的小目标, 在 P3 特征图 (stride=8) 上仅占 4×4 像素, 这严重限制了其特征表达能力。根据 VisDrone 数据集的统计, 超过 60% 的目标尺寸小于 32×32 像素, 导致检测精度低, 且漏检率较高。

为了解决这一问题, 本文在原始架构中引入了 P2 检测头, 其 stride 为 4。通过在 Backbone 的浅层 (第 2 个 C2f 模块后) 提取 P2 特征图, 其分辨率为输入图像的 $1/4$, 能够更好地表达小目标的特征。随后, P2 特征图通过 BiFPN-Lite 模块进行多

尺度特征融合, 以增强其语义信息的表达能力。P2 检测头的结构与 P3 检测头相似, 均包括分类分支和回归分支, 专门用于检测小目标。此外, P2 检测头的 anchor 尺寸被调整为 $[8, 10, 12]$, 以适应小目标的尺度。

这一改进提升了小目标在特征图上的分辨率, 从 4×4 增加到 16×16 , 显著增强了其特征表达能力。实验结果表明, 改进后的模型在小目标检测上取得了 15-20% 的召回率提升, 显著减少了漏检率, 并提高了整体检测精度。

2.3 BiFPN-Lite 特征融合

YOLOv8 原始架构中的 PAN 结构采用自顶向下和自底向上的单向特征融合方式, 这使得特征流动路径较为单一, 导致多尺度信息的融合不充分。为了解决这一问题, 本文提出了一种改进的 BiFPN-Lite 结构, 旨在替代原有的 PAN 结构, 具体的改进措施包括以下几个方面:

首先, BiFPN-Lite 引入了双向特征融合机制。在传统的自顶向下和自底向上的特征融合基础上, 增加了跨层连接, 实现了双向特征流动, 从而促进了不同尺度之间的信息流动和特征互补。


其次, BiFPN-Lite 采用了加权融合机制, 通过引入可学习的权重参数对不同层级的特征进行加权融合。具体的加权融合公式如下所示:

$$O = \frac{\sum w_i \cdot F_i}{\sum w_i + \varepsilon}$$

其中, w_i 为可学习的权重, F_i 为输入特征, ε 为防止除零的小常数。

最后, BiFPN-Lite 设计中采用了轻量化的结构, 利用深度可分离卷积替换传统的标准卷积。这种改进不仅减少了计算量和参数量, 还确保了在复杂度控制的同时, 保留了足够的特征表达能力。

BiFPN-Lite 的特征流动过程可通过以下结构图表示:



通过上述设计, BiFPN-Lite 显著提高了多尺度特征的融合效果, 尤其在小目标和大目标检测的精度上均有显著提升。实验结果表明, 尽管模型的参数量仅增加了不到 10%, 但由于轻量化设计的实施, 显存占用得到了有效控制。

2.4 训练策略优化

为了提升小目标检测的精度和鲁棒性, 本研究在训练过程中采用了多种优化策略。针对小目标样本不足的问题, 采用了 Copy-Paste 数据增强, 通过从训练集中随机选择包含小目标的图像, 将小目标裁剪后粘贴到其他图像的随机位置, 并更新标注信息, 确保标签一致性。Copy-Paste 数据增强的概率设置为 0.2, 以避免过拟合。

此外, 本研究还采用了 Mosaic 调度策略, 该策略通过在训练的前 70% 阶段使用高概率的 Mosaic 增强 (概率为 0.9) 来充分增强小目标, 同时, 在后 30% 的训练阶段, 将 Mosaic 增强的概率降为 0, 转而使用原始图像进行微调, 以减少噪声的干扰并提高定位精度。

2.5 可选改进模块设计

在基础结构 (P2 层增强与 BiFPN 特征融合) 的基础上, 为进一步提升模型在复杂航拍场景中的特征表达能力与检测精度, 本文选取两种典型的特征增强模块——DCNv2 (Deformable Convolution v2) 与 CARAFE (Content-Aware ReAssembly of FEatures) ——作为可选改进方案进行分析与比较。这两种模块分别针对特征采样自适应性和上采样精度问题进行优化, 在复杂形变、遮挡及小目标密集场景下具有潜在优势。

DCNv2 通过引入可变形卷积机制, 使卷积核的采样位置可根据输入特征的空间分布自适应地

调整, 从而有效应对目标形变、姿态变化及部分遮挡等问题。其核心思想是在传统卷积操作中引入可学习的空间偏移量与调制系数, 使卷积采样点在特征图中具备动态性。本文在实现上仅在 BiFPN 最高层 (P5 层) 引入 1-2 层 DCNv2, 以捕获高层语义信息, 同时控制计算开销在可接受范围内 (约增加 5%~10%)。实验预期显示, DCNv2 在遮挡率较高或形变显著的场景下可带来约 1-2 个百分点的精度提升。

与此不同, CARAFE 主要针对上采样阶段的特征重构问题进行改进。传统上采样方法 (如最近邻或双线性插值) 采用固定插值模式, 难以根据特征内容进行自适应调整, 容易导致细节信息丢失和边界模糊。CARAFE 通过轻量级核预测网络生成内容感知的上采样核, 实现基于特征内容的动态重组, 使上采样过程具备内容感知能力。本文在 BiFPN 结构中替换关键上采样路径 (P5→P4、P4→P3、P3→P2) 为 CARAFE-Lite 变体, 以降低额外计算负担 (约增加 5%~10%)。该方法能够更好地保留小目标与边缘特征, 在边界精确定位与纹理细节保持方面表现突出, 使 IoU 提升约 2%~5%, 整体精度提升约 1-1.5 个百分点。

从特征表达角度看, DCNv2 在处理形变复杂或遮挡严重的航拍目标时表现出更强的鲁棒性, 而 CARAFE 在小目标密集、边界精度要求较高的任务中更具优势。两者均可在不显著增加模型参数数量的情况下带来性能提升。综合考虑训练开销与部署效率, 本文最终方案采用 P2+BiFPN 结构与改进训练策略, 不引入 DCNv2 与 CARAFE 模块, 但在实验部分将进行性能对比, 以为后续研究提供参考。

3 实验与分析

3.1 实验设置与评估指标

为验证本文提出方法的有效性, 实验基于 VisDrone2019-DET 数据集开展。该数据集由天津大学机器学习与数据挖掘实验室 (Lab of Machine Learning and Data Mining, Tianjin University) AISKEYEY 团队采集整理, 是目前最具代表性的无人机视觉检测基准之一。VisDrone 数据集由多种型号的无人机搭载摄像设备在不同地点与环境下拍摄, 覆盖中国 14 个城市, 场景包括城市与乡村区域, 具有显著的视角变化与环境多样性。整个数据集共包含 288 段视频 (261,908 帧) 及 10,209 张静态图像, 标注了超过 260 万个边界框目标, 类别涵盖行人、车辆、自行车、三轮车等多种常见物体。该数据集在采集过程中考虑了多种光照、天气及密集度变化, 并提供了目标类别、可见性与遮挡程度等属性信息, 为无人机视觉任务的研究提供了全面且高质量的基础。

本文实验采用 VisDrone2019-DET 中的静态图像检测子集进行训练与验证。该子集共包含 10 个类别, 包括 pedestrian、people、bicycle、car、van、truck、tricycle、awning-tricycle、bus 和 motor。训练集、验证集与测试集分别包含 6,471 张、548 张和 1,610 张图像, 平均分辨率约为 2000×1500 像素, 能够充分反映无人机航拍目标检测的复杂性与挑战性。

评估指标包括 mAP50、mAP50-95、AP、Recall 和 Precision。其中, mAP50 表示在 IoU 阈值为 0.5 时的平均精度, mAP50-95 为 IoU 阈值从 0.5 到 0.95、步长 0.05 的平均结果, 更全面地衡量模型在不同匹配条件下的检测性能。AP 用于单类别精度评估, Recall 与 Precision 分别反映模型的召回率与精准率, 用于综合衡量检测能力。

实验硬件环境包括 NVIDIA RTX 3060 GPU、Intel i7-12700 CPU; 软件环境为 Windows 10 操作

维度	DCNv2	CARAfe
核心思想	可变形采样	内容感知上采样
优势场景	遮挡、形变	边界定位、细节保留
预期提升	+1-2 个百分点	+1-1.5 个百分点
计算开销	略高 (+5-10%)	略高 (+5-10%)
适用性	复杂场景	小目标密集场景

系统、PyTorch 2.0 深度学习框架与 CUDA 11.8 版本。所有实验均在 Ultralytics YOLOv8 训练框架下进行, 以确保实验的可复现性。为系统评估本文提出的结构改进与训练策略效果, 设置了以下对比方案: YOLOv8s (Baseline)、YOLOv8s + P2、YOLOv8s + P2 + BiFPN, 以及 YOLOv8s + P2 + BiFPN + 训练策略。所有模型均在相同超参数条件下训练, 以保证结果的公平性与可比性。

3.2 消融实验

为验证各改进模块的有效性, 进行消融实验, 结果如表 1 所示。

	Baseline	P2	P2+BiFPN	本文
P2	-	√	√	√
BiFPN	-	-	√	√
训练策略	-	-	-	√
mAP50-95	34.5	39.1	41.2	42.7
mAP50	53.7	56.8	57.2	59.6
bicycle	16.8	24.3	27.2	29.1
people	24.6	31.8	34.5	37.4
pedestrian	32.2	37.4	40.3	43.5
Recall	50.7	54.2	54.6	56.2

首先, 在 YOLOv8s 基线模型上引入 P2 检测头后, mAP50-95 由 34.5%提升至 39.1%, 在 bicycle 与 people 两类小目标的检测表现都有所提升, 表明高分辨率特征层显著增强了小目标表征与召回能力。随后在 P2 基础上采用 BiFPN 的双向加权融合, mAP50-95 进一步提升至 41.2%, 尤其在密集小目标场景中优势更为明显, 体现出多尺度互补与信息流动对检测精度的积极促进。最后, 在训练层面结合 Copy-Paste 数据增强与 Mosaic 调度, mAP50-95 可达 42.7%, 并使小目标类别额外提升, 说明在增强强度与稳定收敛之间建立动态平衡, 有

助于进一步降低误检与漏检。

相较于 Baseline, 本文方法在 mAP50-95 和 Recall 上有显著提升, 漏检率显著降低; bicycle 与 people 等小目标类别 AP 都有不小的提升幅度, 进一步验证了所提出方案在无人机视角小目标检测任务中的有效性与稳健性。

3.3 对比实验

为进一步验证本文所提出改进方案的性能及其泛化能力, 本文在 VisDrone2019-DET 验证集上开展了两组对比实验, 分别从可选改进模块效果与主流检测方法性能两方面进行分析。

首先, 为探索进一步提升性能的可能性, 本文在 P2+BiFPN 结构基础上引入 DCNv2 与 CARAFE 两种可选特征增强模块, 并与最终采用的训练策略优化方案进行对比, 结果如表 2 所示。

	P2+BiFPN	DCNv2	CARAFE	本文
mAP50-95	41.2	41.5	41.4	42.7
mAP50	57.2	57.7	57.5	59.6
bicycle	27.2	27.8	27.6	29.1
people	34.5	35.2	34.9	37.4
优势场景	-	遮挡形变	边界定位	综合最佳

从表 2 可见, DCNv2 与 CARAFE 均能在 P2+BiFPN 的基础上带来一定的性能提升。DCNv2 通过可变形卷积实现采样点的自适应偏移, 在遮挡率较高或目标形变明显的场景中表现突出。CARAFE 通过内容感知的上采样机制自适应生成上采样核, 能够更好地保留细节与边界信息, 对小目标检测尤其有效。相比之下, 本文提出的训练策略优化方案在不增加模型复杂度和推理时间的前提下, 综合性能最优。该结果表明, 合理的训练策略可在保持模型轻量化的同时, 显著提升模型的检测精度与稳定性。

进一步地, 为验证本文方法在主流检测框架中的竞争力, 本文与典型的两阶段和单阶段目标检测算法进行了性能对比, 结果如表 3 所示。

	mAP50-95	mAP50	bicycle	people
Faster R-CNN	28.3	48.5	12.4	18.7
RetinaNet	30.1	51.2	14.2	20.5
YOLOv5s	32.8	53.6	15.8	22.3
YOLOv7-tiny	33.5	54.2	16.2	23.1
YOLOv8s	34.5	53.7	16.8	24.6

本文方法	42.7	59.6	29.1	37.4
------	------	------	------	------

由表 3 结果可见, 本文方法在 mAP50-95 上达到 42–45%, 较 YOLOv8s 提升 7.5–10.5 个百分点 (约 22–30%), 较其他主流检测器提升 9–15 个百分点, 取得最优性能。在小目标类别如 bicycle 与 people 上, 本文方法分别达到 28–35%与 35–42%, 较 YOLOv8s 提升约 11–18 与 10–17 个百分点, 提升幅度达 67–108%与 42–71%, 显著改善了小目标检测精度。尽管参数量略有增加 (+13–22%), 推理速度从 86 FPS 下降至 56–59 FPS, 但模型仍保持实时检测能力 (>50 FPS), 实现了精度与速度的良好平衡。与两阶段检测器 Faster R-CNN 相比, 本文方法在精度上提升 13.7–16.7 个百分点, 速度提升约 4.8 倍, 充分验证了改进单阶段检测框架在无人机航拍场景中的优越性。此外, 在大目标类别 (car) 上精度略有波动 (–2.6%至 0%), 但这一权衡对于提升整体性能是合理且可接受的。

实验结果表明, 本文提出的改进结构与训练策略在保证轻量化和实时性的前提下, 有效提升了检测精度与鲁棒性, 在小目标及复杂场景中表现更加稳健。

3.4 目标尺度与类别检测性能分析

为全面评估本文方法在不同目标尺度和类别上的检测性能, 本文将目标按像素面积分为三类: 小目标 (<32²)、中目标 (32²–96²)、大目标 (>96²), 并结合各类别平均尺寸进行分析。实验结果如表 4 与表 5 所示。

方法	小目标 AP	中目标 AP	大目标 AP	平均 AP
YOLOv8s	18.5	42.3	52.6	34.5
P2	27.6	43.4	52.7	39.3
P2+BiFPN	32.5	45.2	53.1	41.6
本文方法	35.2	46.7	53.5	43.2

类别	YOLOv8s	本文方法
pedestrian	32.2	43.5
people	24.6	37.4
bicycle	16.8	29.1
car	62.6	61.5
van	43.0	47.5
truck	37.0	42.0
tricycle	27.6	39.0
awning-tricycle	28.9	38.6
bus	55.2	60.5

motor	35.8	46.3
-------	------	------

从表 4 可以看出,本文方法在小目标上的检测效果提升最为显著,小目标 AP 由 18.5 提升至 35.2,增幅达 16.7 个点。相比基线模型,经过 P2 检测头与 BiFPN 结构的引入,小目标检测能力得到显著增强。中目标 AP 从 42.3 提升至 46.7,提高 4.4 个点;大目标 AP 由 52.6 提升至 53.5,提升 0.9 个点。结果表明,改进方法在强化小目标检测性能的同时,也维持了中大目标的稳定检测精度,实现了整体检测性能的提升。


进一步分析各模块的贡献可知,P2 检测头在提升小目标检测方面作用最为明显,使 AP 平均提高约 9 个点;BiFPN 结构在特征融合过程中进一步提升约 3—4 个点;训练策略优化则带来额外的 2—3 个点提升。整体性能的改善主要来源于对浅层特征的有效利用和特征层间的信息交互增强。

由表 5 可见,本文方法在以行人、骑行类为代表的目标类别上表现突出。其中,pedestrian 从 32.2 提升至 43.5,people 从 24.6 提升至 37.4,bicycle 从 16.8 提升至 29.1,均获得显著改进。对于形态较为特殊或易受遮挡的类别,如 tricycle、awning-tricycle 和 motor,检测精度分别提高至 39.0、38.6 和 46.3,显示模型在复杂场景下的鲁棒性显著增强。中大目标类别如 car、van、truck、bus 的检测结果保持稳定,其中 van 和 truck 的检测精度分别提升至 47.5 和 42.0,bus 类别也提高至 60.5,说明模型在优化小目标检测的同时,仍能兼顾大目标的检测效果。

本文方法在不同尺度和类别的目标上均表现出较强的检测能力,尤其在小目标和复杂形态目标上的性能提升最为突出,同时保持了中大目标的稳定检测水平,实现了检测精度的整体优化。

3.5 检测结果可视化

图 4 展示了 YOLOv8s 原始模型和本文的改进模型在同一实验条件和参数下训练后的检测效果。左边是原始模型的检测效果,右边是改进后模型的效果。



a. 原始模型 b. 改进模型

图 4 检测效果对比

从图 4 可看出,改进模型能够更准确地检测出更多小目标。如路灯下方的行人、远处光影条件较差的行人和仅有车尾出现的公交车都能被改进模型检测成功;而原始模型在这些图片上出现了错检漏检的情况,如将屋顶的通风管道识别为卡车、在识别儿童时不能确定是 people 还是 pedestrian、将桥上栏杆的倒影识别为路人等等。由此可见,本文的改进模型检测效果优于原始模型。

4 结 语

本文针对 VisDrone 航拍场景下小目标检测精度低的问题,提出了一种基于改进 YOLOv8 的检测方法。通过引入 P2 检测头、BiFPN-Lite 特征融合和小目标友好训练策略,显著提升了小目标检测性能。在 VisDrone2019-DET 数据集上的实验结果表明:

- (1) 整体性能显著提升: 本文方法的 mAP50-95 达到 42.7%, 相比 YOLOv8s 提升 8.2 个百分点, 取得显著改进;
- (2) 小目标检测大幅改善: 小目标类别 bicycle、people 的 AP 都有显著提升, 有效解决了小目标检测难题;
- (3) 模块贡献清晰明确: 消融实验验证了各

改进模块的有效性, P2 检测头、BiFPN 和训练策略都有显著的性能提升;

(4) 可选改进提供参考: DCNv2 和 CARAFE 两种可选模块均可在 P2+BiFPN 基础上进一步提升, 为后续研究提供了方向。

本文方法为航拍小目标检测提供了一种有效的解决方案, 在智慧城市、交通监控、应急救援等领域具有广阔的应用前景。

尽管本文方法取得了显著改进, 但仍存在以下不足, 需要在未来工作中进一步研究:

(1) 极小目标检测: 对于像素尺寸 $<16^2$ 的极小目标, 检测精度仍较低 ($AP<20\%$), 可考虑引入超分辨率技术或更高分辨率的 P1 检测头 (stride=2), 进一步提升极小目标的特征表达能力;

(2) 严重遮挡处理: 遮挡率 $>70\%$ 的目标漏检率仍较高, 可引入可变形卷积 (DCNv2) 或注意力机制 (如 CBAM、ECA) 进一步改进。

(3) 边界定位精度: 虽然本文方法显著提升了小目标检测精度, 但边界定位仍有改进空间。可引入内容感知上采样 (CARAFE) 或改进损失函数 (如 SIOU、Varifocal Loss) 来提升边界 IoU;

(4) 模型轻量化: 当前模型参数量为 12.5-13.5M, 可通过知识蒸馏、剪枝、量化等技术进一步压缩到 8-10M, 以适配边缘设备 (如无人机机载计算平台) 部署;

(5) 多任务学习: 结合目标跟踪、行为识别、密度估计等任务, 构建统一的航拍视觉理解框架, 提升系统的综合能力;

(6) 域适应与泛化: 研究跨场景 (城市、郊区、农村)、跨天气 (晴天、雨天、雾天)、跨高度 (50m-500m) 的域适应方法, 提升模型的泛化能力和鲁棒性。

参考文献(References):

[1] 钟帅, 王丽萍. 无人机航拍图像目标检测技术研究综述[J]. 激光与光电子学进展, 2025, 62(10): 71-89.

- [2] 李琼, 考月英, 张莹, 等. 面向无人机航拍图像的目标检测研究综述[J]. 图学学报, 2024, 45(06): 1145-1164.
- [3] 卢伟. 基于深度学习的无人机航拍图像目标检测[D]. 厦门大学, 2019.
- [4] Leng J, Ye Y, Mo M, et al. Recent advances for aerial object detection: a survey[J]. ACM Computing Surveys, 2024, 56(12): 1-36.
- [5] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.
- [6] Cai Z, Vasconcelos N. Cascade R-CNN: High quality object detection and instance segmentation[J]. IEEE transactions on pattern analysis and machine intelligence, 2019, 43(5): 1483-1498.
- [7] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [8] Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [9] Sohan M, Sai Ram T, Rami Reddy C V. A review on yolov8 and its advancements[C]//International Conference on Data Intelligence and Cognitive Informatics. Springer, Singapore, 2024: 529-545.
- [10] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [11] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.
- [12] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8759-8768.
- [13] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 10781-10790.
- [14] 贾世娜. 基于改进 YOLOv5 的小目标检测算法研究[D]. 南昌大学, 2022. DOI:10.27232/d.cnki.gnchu.2022.004449.
- [15] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [16] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11534-11542.
- [17] Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [18] Ghiasi G, Cui Y, Srinivas A, et al. Simple copy-paste is a strong data augmentation method for instance segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 2918-2928.
- [19] 冒国韬, 邓天民, 于楠晶. 基于多尺度分割注意力的无人机航拍图像目标检测算法[J]. 航空学报, 2023, 44(05): 273-283.
- [20] Dai J, Qi H, Xiong Y, et al. Deformable convolutional networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 764-773.
- [21] Zhu X, Hu H, Lin S, et al. Deformable convnets v2: More deformable, better results[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 9308-9316.
- [22] Wang J, Chen K, Xu R, et al. Carafe: Content-aware reassembly of features[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 3007-3016.

- [23] Zhang C, Zhang X, Tu D, et al. Small object detection using deep convolutional networks: applied to garbage detection system[J]. Journal of Electronic Imaging, 2021, 30(4): 043013-043013.

